



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Módulo 1. Programación en Python

Presenta: Erick Varela Guzmán.

Contacto: evarela@uca.edu.sv


Universidad Centroamericana José Simeón Cañas.

Objetivos de esta sesión

1. Aprender sobre el análisis exploratorio de datos (EDA) utilizando Python para obtener insights significativos.
2. Desarrollar habilidades prácticas para manipular y explorar datos, incluyendo la inspección de estructuras de datos, manejo de valores faltantes, análisis de variables y relaciones, y la identificación de patrones mediante herramientas estadísticas y visualizaciones básicas.
3. Aplicar técnicas fundamentales de EDA en casos prácticos, utilizando pandas para preparar, transformar y analizar un conjunto de datos real, con énfasis en la identificación de tendencias, outliers y oportunidades de mejora en la calidad de los datos.

5.1

Introducción al análisis exploratorio de datos.




Definición

- El **análisis exploratorio de datos (EDA)**, es el proceso inicial en el análisis de datos que permite explorar, resumir y visualizar las características principales de un conjunto de datos.
- Su propósito es proporcionar una comprensión inicial de los datos, detectar patrones, identificar valores atípicos y evaluar su calidad **antes de aplicar técnicas avanzadas como modelado predictivo o aprendizaje automático.**
- El EDA es fundamental para descubrir problemas en los datos, como valores faltantes o inconsistencias, y para guiar las decisiones sobre cómo manejarlos.

Objetivos de realizar un proceso EDA.

- **Comprender la estructura de los datos.** Obtener información sobre el tamaño, las dimensiones, y los tipos de variables presentes en el conjunto de datos.
- **Evaluar la calidad de los datos.** Detectar valores nulos, duplicados, valores fuera de rango y otros problemas que puedan afectar el análisis posterior.
- **Identificar relaciones y patrones.** Descubrir correlaciones entre variables, tendencias generales y agrupaciones naturales en los datos.
- **Preparar los datos para análisis avanzado.** Transformar, limpiar y estructurar los datos de manera que sean adecuados para técnicas de modelado y visualización avanzadas.

Proceso EDA




Herramientas

En Python, existen diversas herramientas que permiten inspeccionar, limpiar y analizar datos de manera eficiente.

- **Pandas:** Ideal para manipulación y análisis de datos tabulares. Ofrece métodos para limpieza, transformación y análisis básico.
- **NumPy:** Soporte para cálculos numéricos eficientes.
- **Matplotlib y Seaborn:** Herramientas de visualización que facilitan la creación de gráficos para explorar patrones y distribuciones.
- **Scikit-learn:** Incluye funciones para análisis estadístico y preprocesamiento de datos.
- **Sweetviz y pandas-profiling:** Generan reportes automáticos para un EDA rápido y completo.

5.2


Análisis exploratorio de datos en el entorno de Python.



Librería Pandas

- **Pandas** es una biblioteca de Python diseñada específicamente para la manipulación y análisis de datos estructurados.
- Es una de las herramientas más populares y poderosas en el ecosistema de Python para científicos de datos, analistas y desarrolladores.
- Su objetivo principal es facilitar el trabajo con datos tabulares y series temporales.
- Pandas es una herramienta esencial para cualquier proyecto de análisis de datos, ofreciendo un flujo de trabajo eficiente desde la importación hasta la visualización de resultados.





Ejemplos prácticos: exploración inicial de Pandas.

Ejemplo 5.1. Importando librería Pandas

Ejemplo 5.2. Ejemplos de estructuras de datos en Pandas: Series y Dataframes.

Ejemplo 5.3. Importación de bancos de datos en Pandas

Ejemplo 5.4. Exploración inicial de los datos importados

Ejemplo 5.5. Corrigiendo tipos de datos e inconsistencias

Importación de datos con Pandas

La librería Pandas permite importar datos fácilmente y desde diversas fuentes. Se puede trabajar con archivos locales o fuentes externas en formatos como:

Archivos CSV:

```
df = pd.read_csv('archivo.csv')
```

Importación de datos con Pandas

La librería Pandas permite importar datos fácilmente y desde diversas fuentes. Se puede trabajar con archivos locales o fuentes externas en formatos como:

Archivos XLSX:

```
df = pd.read_excel('archivo.xlsx', sheet_name='Hoja1')
```

Importación de datos con Pandas

La librería Pandas permite importar datos fácilmente y desde diversas fuentes. Se puede trabajar con archivos locales o fuentes externas en formatos como:

Archivos de bases de datos SQLite:

```
import sqlite3

conn = sqlite3.connect('mi_base_de_datos.db')
df = pd.read_sql_query('SELECT * FROM tabla', conn)
```



Sección de discusión y preguntas



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Módulo 2. Programación en Python

Fin de la presentación