



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Presenta: Erick Varela Guzmán.

Contacto: evarela@uca.edu.sv

Universidad Centroamericana José Simeón Cañas.

Objetivos de esta sesión


- Analizar la evolución del perceptrón hacia redes neuronales multicapa, comprendiendo sus limitaciones iniciales y cómo se superan mediante arquitecturas más complejas.
- Discutir los conceptos fundamentales de las redes neuronales.
- Aplicar redes neuronales en dos casos prácticos, desarrollando un ejemplo de clasificación y otro de regresión para ilustrar su funcionamiento en distintos tipos de problemas.

3.1

Perceptrón multicapa







Fundamento de las redes neuronales




Perceptrón Multicapa

Fundamento de las redes neuronales



Función de activación

Fundamento de las redes neuronales




Fundamentos

- El Perceptron Multicapa (PM) fue propuesta por Rumelhart y otros autores (1986) y surgió con el objetivo de solventar las limitaciones encontradas en el Perceptron Simple frente a su incapacidad para resolver problemas no lineales*.
- El modelo de trabajo es feed-forward, es decir que el flujo fluye en una sola dirección, desde la entrada hasta la salida, sin bucles ni conexiones hacia atrás.
- Modelo de aprendizaje supervisado.

* **Fuente:** Rumelhart, D., Hinton, G. & Williams, R. Learning representations by back-propagating errors. Nature 323, 533–536 (1986). <https://doi.org/10.1038/323533a0>

Modelo computacional



Fundamentos

- **Capa de entrada:** sólo se encargan de recibir los datos de entrada y propagarlas a la siguiente capa
- **Capa de salida:** se encargan de proporcionar la respuesta de la red
- **Capas ocultas:** realizan el procesamiento no lineal de los datos recibidos desde la capa de entrada
- Generalmente cada neurona está conectada a todas las neuronas de la siguiente capa (conectividad total).

Fundamentos

Considerando un perceptrón multicapa de 2 capas, para calcular la salida de la primera capa:

$$H_1 = f_1(\sum(w_1 * x) + U_1)$$

Donde:

- f_1 : función de activación de la primera capa
- w_1 : conjunto de pesos
- x : conjunto de valores de entrada

Fundamentos

Continuando con el ejemplo anterior (perceptrón multicapa de dos capas), para calcular la salida de la capa 2 (estimación del perceptrón multicapa) se tiene:

$$\hat{y} = f_2(\sum(w_2 * H_1) + U_2)$$

Sustituyendo H1:

$$\hat{y} = f_2(\sum(w_2 * f_1(\sum(w_1 * x) + U_1)) + U_2)$$

La siguiente pregunta es, ¿Cómo se entrena el modelo?

Fundamentos

Para calcular la regla de aprendizaje en un perceptrón multicapa se suele calcular el error medio cuadrático (MSE)

$$MSE(\hat{y}, y) = \frac{1}{N} \sum_{j=1}^N (\hat{y}^j - y^j)^2$$

Para obtener más información del error medio cuadrático puede acceder a:

<https://support.numxl.com/hc/es/articles/115001223423-MSE-Error-Cuadr%C3%A1tico-Medio>

Método de propagación hacia atrás

Procedimiento para definir la regla de aprendizaje:

1. Calcula la predicción $\hat{y}$ del perceptrón multicapa
2. Calcular la derivada del error medio cuadrático con respecto a los pesos $\frac{\partial MSE}{\partial w}$
3. Actualizar los pesos $w = w - \eta \frac{\partial MSE}{\partial w}$
4. Repetir la cantidad de iteraciones definidas o hasta converger (que la diferencia entre los pesos de la iteración n y $n+1$ sea despreciable).

Método de propagación hacia atrás

Continuando con el ejemplo del perceptrón multicapa de dos capas. Para calcular el método de propagación hacia atrás, se inicia calculando la derivada de la última capa primero:

$$\frac{\partial MSE}{\partial w_2} = \frac{\partial MSE}{\partial \hat{y}} * \frac{\partial \hat{y}}{\partial w_2} = \frac{2}{n} (\hat{y} - y) * h_1$$

Calculando el método de propagación hacia atrás de la primera capa:

$$\frac{\partial MSE}{\partial w_1} = \frac{\partial MSE}{\partial h_1} * \frac{\partial h_1}{\partial w_1} = \frac{\partial MSE}{\partial \hat{y}} * \frac{\partial \hat{y}}{\partial h_1} * \frac{\partial h_1}{\partial w_1} = \frac{2}{n} (\hat{y} - y) * w_2 * \partial(w_1 * x) * x$$









Funciones de activación

- Las funciones de activación permiten a las redes neuronales aprender patrones complejos en los datos. Transforman la señal de entrada de un nodo de una red neuronal en una señal de salida que luego se pasa a la siguiente capa. Sin funciones de activación, las redes neuronales se limitarían a modelar únicamente relaciones lineales entre entradas y salidas.
- Las funciones de activación introducen no linealidades, lo que permite que las redes neuronales aprendan asignaciones altamente complejas entre entradas y salidas.


Utilidad de las funciones de activación

- Cada neurona de un perceptrón multicapa realiza una suma ponderada de sus entradas con los pesos correspondientes, el resultado de esta operación es una **salida lineal**
- Con la suma de todas estas salidas lineales, sin duda obtendremos una salida lineal del modelo
- Por lo tanto, un perceptrón multicapa con una salida lineal no es diferente a un modelo con un solo perceptrón. Por esta razón las posibilidades de aplicación de un perceptrón multicapa serían muy limitadas.

Ejemplos funciones de activación



Crterios recomendados




¿Cual función de activación debo usar?

- Para clasificación binaria, se suele utilizar la función de activación sigmoidea en la capa de salida.
- Para clasificación de clases múltiples, utilizar softmax en la capa de salida generará distribuciones de probabilidad para todas las clases.
- Para las capas ocultas, ReLU es la función de activación predeterminada más común y suele ser una buena opción.

Criterios recomendados

Caso/Tarea	Optimizador	Función de Pérdida	Métricas
Clasificación Binaria	Adam, RMSprop, SGD	Binary Crossentropy	Accuracy, Precision, Recall, 'F1-Score
Clasificación Multiclase	Adam, RMSprop, SGD	Categorical Crossentropy	Accuracy, Precision, Recall, 'F1-Score
Clasificación Multietiqueta	Adam, RMSprop, SGD	Binary Crossentropy	Accuracy, Precision, Recall, 'F1-Score
Regresión	Adam, RMSprop, SGD	Mean Squared Error (MSE)	Mean Absolute Error (MAE), R2 Score
Detección de Objetos	Adam, RMSprop, SGD	Region Proposal Network (RPN), Smooth L1 Loss	Mean Average Precision (mAP)
Segmentación de Imágenes	Adam, RMSprop, SGD	Crossentropy, Dice Loss	Intersection over Union (IoU), Dice Coefficient
Redes Generativas Adversarias	Adam, RMSprop	Binary Crossentropy (Discriminator), Various for Generator	FID (Fréchet Inception Distance), Inception Score
Secuencia a Secuencia (NLP)	Adam, RMSprop, SGD	Categorical Crossentropy, Sparse Categorical Crossentropy	BLEU Score, Perplexity
Detección de Anomalías	Adam, RMSprop, SGD	Mean Squared Error (Reconstruction Error)	Area Under the Receiver Operating Characteristic (AU-ROC)
Aprendizaje por Transferencia	Adam, RMSprop, SGD	Task-specific loss function	Task-specific evaluation metrics




Ejemplos prácticos

Ejemplo 2. Creación de red neuronal para categorizar clientes en base a un criterio de fidelidad.


Proceso codificación “one-hot”

Técnica que convierte datos categóricos en valores numéricos. Es una forma común de preparar datos categóricos para modelos de aprendizaje automático. Esta técnica permite que cada categoría se trate de forma independiente, mejorando la precisión de la predicción.




Técnicas de regularización

La regularización consiste en diferentes técnicas y métodos que se utilizan para abordar el problema del sobreajuste, reduciendo el error de generalización sin afectar significativamente el error de entrenamiento.




Proceso de regularización (“dropout”)

Técnica de regularización que se basa en la eliminación aleatoria de neuronas. El objetivo principal de esta técnica es esencialmente mitigar la posible aparición del fenómeno conocido como overfitting o sobreajuste,



Detención temprana (“early stopping”)

Técnica usada en procesos de aprendizaje automático para evitar el overfitting. También, ayuda a ahorrar tiempo y recursos de computación. Consiste en interrumpir el entrenamiento antes de que el modelo comience a perder capacidad de generalización, es decir, cuando el desempeño sobre los datos de validación empieza a empeorar.





Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Fin de presentación.