



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Presenta: Erick Varela Guzmán.

Contacto: evarela@uca.edu.sv

Universidad Centroamericana José Simeón Cañas.

Objetivos de esta sesión

- Diferenciar los problemas de regresión de los de clasificación e identificar cuándo corresponde plantear cada uno.
- Construir una red neuronal de regresión, reconociendo los cambios en la capa de salida, la función de pérdida y el tratamiento de la variable objetivo.
- Interpretar las métricas de evaluación de clasificación y de regresión, reconociendo sus límites y los riesgos de leer una sola métrica.

5.1

Regresión con redes neuronales



¿Qué es un problema de regresión?

- La red estima una **cantidad continua**: un precio, una temperatura, un tiempo de entrega, una demanda.
- La salida puede tomar **infinitos valores** dentro de un rango; no existe un conjunto cerrado de categorías.
- El acierto deja de ser binario: ya no hay respuestas correctas e incorrectas, sino predicciones **más o menos cercanas** al valor real.
- Por eso la evaluación se apoya en la **magnitud del error**, no en el conteo de aciertos.

Regresión frente a clasificación

- **Variable objetivo:** continua en regresión, discreta y finita en clasificación.
- **Capa de salida:** una neurona con activación lineal frente a sigmoide o softmax.
- **Función de pérdida:** error cuadrático medio frente a entropía cruzada.
- **Evaluación:** MAE, RMSE y R^2 frente a accuracy, precisión, recall y F1.
- **Interpretación:** cuánto se equivoca el modelo frente a con qué frecuencia se equivoca.

¿Cuándo conviene un caso de regresión?

- Cuando la pregunta del negocio empiece con **¿cuánto?** y no con **¿cuál?** o **¿es o no es?**
- Cuando el **orden y la distancia** entre los valores importan: predecir \$12 cuando el real es \$14 es mejor que predecir \$40.
- Cuando categorizar la variable destruiría información útil, por ejemplo agrupar precios en “bajo, medio y alto”.
- Si la decisión final sí es binaria, conviene modelar la cantidad y **aplicar el umbral después**, no antes.

La salida de la red cambia

- **Una sola neurona de salida** con activación lineal: no se acota el resultado a un rango fijo.
- Usar sigmoide o tanh en la salida **limita artificialmente** el valor predicho y sesga el modelo.
- Las **capas ocultas no cambian**: ReLU sigue siendo la activación predeterminada.
- Con varias cantidades a predecir a la vez, se usan varias neuronas lineales en la salida.

Función de pérdida en regresión

- **MSE (error cuadrático medio):** penaliza con fuerza los errores grandes; es la opción por defecto y la más sensible a valores atípicos.
- **MAE (error absoluto medio):** trata todos los errores en proporción a su tamaño; más robusto ante atípicos.
- **Huber:** se comporta como MSE en errores pequeños y como MAE en los grandes.
- La pérdida guía el entrenamiento; la métrica comunica el resultado.
Pueden ser distintas.

Caso 4. Precio de un viaje

- **Dataset:** viajes de Uber y Lyft en Boston, con más de 690,000 registros y precio real.
- **Variable objetivo:** el precio del viaje, una cantidad continua en dólares.
- **Predictoras:** distancia, multiplicador de tarifa dinámica, temperatura, fin de semana, franja horaria, nivel de servicio y empresa.
- **Pregunta:** ¿cuánto costará un viaje con estas condiciones?, no ¿será caro o barato?

Arquitectura del caso 4

- Capas densas de **32 y 16 neuronas** con activación ReLU.
- Normalización por lotes y dropout de 0.2 entre las primeras capas.
- Capa de salida: **una neurona lineal**.
- Compilación con optimizador Adam, pérdida MSE y MAE como métrica de seguimiento.
- Entrenamiento con detención temprana sobre el 20% de validación.

Errores frecuentes en regresión

- **Extrapolar:** pedir predicciones fuera del rango de datos con que se entrenó el modelo.
- **Fuga de datos:** incluir variables que solo se conocen después de observar el valor real.
- **Distribución sesgada:** unos pocos valores extremos dominan el MSE y desplazan todo el ajuste.
- **No comparar contra una línea base:** un modelo debe superar a predecir siempre el promedio.

5.2

Métricas de evaluación



Métrica y función de pérdida

- La **función de pérdida** es la que el modelo optimiza; debe ser derivable y estable durante el entrenamiento.
- La **métrica** es la que se reporta y se interpreta; debe ser comprensible para quien toma la decisión.
- Un mismo modelo puede entrenarse con MSE y comunicarse con MAE, porque este último se lee en las unidades del problema.
- Ninguna métrica resume por sí sola el comportamiento del modelo: se leen **en conjunto**.

Matriz de confusión

- Cruza lo que el modelo predijo contra lo que realmente ocurrió.
- **Verdaderos positivos y verdaderos negativos:** aciertos del modelo.
- **Falsos positivos:** el modelo alerta sin motivo. **Falsos negativos:** el modelo deja pasar un caso real.
- Todas las métricas de clasificación se derivan de estas cuatro celdas; **es el punto de partida**, no un detalle técnico.

Accuracy: qué mide y cuándo engaña

- Proporción de predicciones correctas sobre el total de casos.
- Con **clases desbalanceadas** pierde sentido: si el 97% de las transacciones son legítimas, predecir siempre “legítima” alcanza 97% de accuracy sin detectar un solo fraude.
- Trata por igual todos los errores, aunque **falso positivo y falso negativo cuesten muy distinto**.
- Es una métrica válida cuando las clases están equilibradas y los errores tienen un costo similar.

Precisión y recall

- **Precisión:** de todo lo que el modelo marcó como positivo, cuánto lo era realmente. Responde por el costo de las falsas alarmas.
- **Recall (sensibilidad):** de todos los positivos reales, cuántos detectó el modelo. Responde por el costo de lo que se deja pasar.
- Existe una **tensión entre ambas**: subir el recall casi siempre reduce la precisión, y a la inversa.
- La elección depende del problema: en un tamizaje médico pesa el recall; en un filtro de correo, la precisión.

F1 y el umbral de decisión

- **F1**: media armónica de precisión y recall; castiga los modelos que sacrifican una de las dos.
- La clasificación no devuelve una clase sino una **probabilidad**: el 0.5 es una convención, no una ley.
- Mover el umbral desplaza el equilibrio entre falsos positivos y falsos negativos sin reentrenar el modelo.
- **ROC-AUC** evalúa el desempeño en todos los umbrales posibles; útil para comparar modelos entre sí.

MAE, MSE y RMSE

- **MAE:** error promedio en las unidades originales. Si el MAE es 2.7, el modelo se equivoca en promedio \$2.70.
- **MSE:** promedio de los errores al cuadrado. Penaliza los errores grandes, pero queda en unidades al cuadrado y no se interpreta directamente.
- **RMSE:** raíz del MSE; vuelve a las unidades originales conservando el castigo a los errores grandes.
- Si RMSE es **mucho mayor** que MAE, existen predicciones muy desviadas en unos pocos casos.

Coeficiente de determinación (R^2)

- Indica qué proporción de la variabilidad de la variable objetivo explica el modelo.
- $R^2 = 1$ es ajuste perfecto; $R^2 = 0$ equivale a predecir siempre el promedio; un valor negativo significa que el modelo es peor que ese promedio.
- No tiene unidades, por lo que permite comparar modelos entre problemas distintos.
- **Advertencia:** siempre sube al agregar variables y puede ser alto aunque el error absoluto sea inaceptable en la práctica.

Errores relativos y MAPE

- **MAPE:** error promedio expresado como porcentaje del valor real; facilita comunicar el resultado al negocio.
- Se indefine cuando el valor real es cero y se dispara cuando es muy pequeño.
- Penaliza de forma asimétrica: castiga más la sobreestimación que la subestimación.
- Un error de \$3 no significa lo mismo en un viaje de \$8 que en uno de \$80: por eso conviene leer el error **absoluto y el relativo juntos**.

Cómo elegir la métrica

- Partir de la **decisión** que se tomará con la predicción, no del catálogo de métricas disponibles.
- Preguntar qué error cuesta más caro y elegir la métrica que lo haga visible.
- Reportar siempre **al menos dos**: una en unidades del problema y otra relativa o comparativa.
- Comparar contra una **línea base trivial**: la clase mayoritaria en clasificación, el promedio en regresión.

Lectura de los resultados del caso 4

- El **MAE** indica en dólares cuánto se desvía en promedio el precio estimado; se compara con el precio medio del viaje.
- Un **RMSE** claramente superior al MAE señala viajes con tarifa dinámica alta mal estimados.
- El **R²** indica cuánta variación del precio explican distancia, servicio y condiciones del viaje.
- El gráfico de **predicho frente a real** muestra dónde falla el modelo, algo que ninguna métrica resumen revela.



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Fin de presentación.