



Universidad Centroamericana José Simeón Cañas

Postgrado en Ciencia de Datos e Inteligencia de Negocios

Tópicos para la ciencia de datos y la toma de decisiones.

Caso de estudio. Riesgo de entrega tardía en la cadena de suministro.

Objetivo del caso

Este caso tiene como propósito principal desarrollar y fortalecer el criterio de decisión necesario para construir una solución de ciencia de datos de extremo a extremo, más que la programación de la red neuronal en sí misma. A partir de un dataset real y sin limpiar del dominio de cadena de suministro, el participante deberá tomar y justificar por escrito decisiones sobre qué información usar, qué información descartar, qué variables construir y cómo interpretar los resultados de un modelo de clasificación binaria, apoyándose en herramientas de inteligencia artificial generativa como asistente técnico en cada etapa, nunca como quien decide.

Al finalizar el caso, el participante habrá practicado el ciclo completo de un proyecto de machine learning aplicado a un problema de negocio: comprensión del contexto, exploración y preparación de datos, ingeniería de variables, construcción y entrenamiento de un modelo de red neuronal, y evaluación de resultados desde una perspectiva de negocio, documentando el razonamiento detrás de cada decisión.

Contextualización

GlobalCart es una empresa de comercio electrónico con operaciones de venta y distribución en varios mercados internacionales (África, Europa, Latinoamérica, Asia-Pacífico y Norteamérica/Centroamérica). Durante los últimos trimestres, el equipo de atención al cliente ha registrado un incremento sostenido en las quejas relacionadas con retrasos en la entrega de pedidos. El equipo de operaciones sospecha que el atraso no ocurre al azar, sino que está asociado a ciertas combinaciones de mercado, modo de envío, categoría de producto y otras características que ya se conocen desde el momento en que se registra el pedido.

La gerencia de operaciones ha solicitado al equipo de ciencia de datos explorar si es posible anticipar el riesgo de atraso de un pedido utilizando únicamente la información disponible al momento en que este se registra, de manera que en el futuro se puedan diseñar alertas o acciones preventivas (por ejemplo, dar seguimiento prioritario a los pedidos identificados como de alto riesgo). Como participante del postgrado, se te asigna esta exploración inicial: no se espera un sistema listo para producción, sino un análisis riguroso, bien documentado y honesto sobre qué tan viable es esta idea con los datos disponibles.

Pregunta de negocio principal: ¿es posible anticipar, con la información disponible al momento de registrar un pedido, si este llegará tarde a su destino?

Preguntas de negocio secundarias: ¿qué variables parecen asociarse más con el riesgo de atraso? ¿el modelo es suficientemente confiable como para apoyar una decisión operativa, o solo como un primer diagnóstico exploratorio?

Glosario técnico

Antes de iniciar, es importante que el equipo comparta un lenguaje común. A continuación se listan términos del dominio de negocio (cadena de suministro) y términos técnicos de machine learning que aparecerán a lo largo del caso.

- **Market:** Agrupación de países en cinco grandes mercados de entrega: África, Europa, LATAM, Pacific Asia y USCA (Estados Unidos y Centroamérica).
- **Shipping Mode:** Modalidad de envío contratada para el pedido: Standard Class, First Class, Second Class o Same Day.
- **Order Status:** Estado administrativo del pedido en el sistema (por ejemplo, COMPLETE, PENDING_PAYMENT, CANCELED, SUSPECTED_FRAUD, entre otros).
- **Late_delivery_risk:** Variable objetivo del caso: indica si un pedido llegó tarde (1) o a tiempo (0).
- **Fuga de datos (data leakage):** Cuando una variable de entrada contiene, directa o indirectamente, información que solo se conocería después de ocurrido el evento que se quiere predecir. Usarla produce un modelo con métricas artificialmente altas pero inútil en la práctica.
- **Ingeniería de variables (feature engineering):** Proceso de crear nuevas variables a partir de las columnas originales del dataset, con el objetivo de que aporten señal adicional al modelo.
- **Codificación one-hot:** Técnica para convertir una variable categórica de texto en columnas numéricas binarias (0/1), una por categoría.
- **Conjunto de entrenamiento / validación / prueba (train / val / test):** División de los datos en tres subconjuntos independientes: uno para ajustar los parámetros del modelo, otro para monitorear el sobreajuste durante el entrenamiento, y uno final que no se toca hasta la evaluación de cierre.
- **Sobreajuste (overfitting):** Cuando un modelo aprende patrones específicos de los datos de entrenamiento (incluyendo ruido) y pierde capacidad de generalizar a datos nuevos.

- **EarlyStopping:** Mecanismo que detiene el entrenamiento de la red cuando la métrica de validación deja de mejorar, para evitar sobreajuste.
- **Matriz de confusión:** Tabla que compara las predicciones del modelo contra los valores reales, mostrando aciertos y tipos de error (falsos positivos y falsos negativos).

Indicaciones generales

- El caso se desarrolla fuera del horario de sesiones (ex-aula). A partir de la fecha de publicación, el equipo cuenta con 5 días calendario para entregarlo.
- El trabajo puede desarrollarse de forma individual o en parejas.
- La entrega consta de dos archivos: el notebook de trabajo (a partir de la guía entregada) y el documento de reporte (memoria de trabajo) con las respuestas a la sección "Reporte de resultados".
- La inteligencia artificial generativa puede y debe utilizarse como asistente técnico en cada etapa (por ejemplo, para redactar código, sugerir variables o explicar un error), pero toda decisión de fondo (qué columnas eliminar, qué variables construir, cómo interpretar un resultado) debe ser tomada y justificada por escrito por el propio equipo. Copiar una sugerencia de la IA sin evaluarla críticamente no constituye una justificación válida.
- El dataset se entrega sin limpiar ni preparar: la selección y preparación de las columnas es parte central del caso, no un paso previo resuelto de antemano.
- Cada decisión relevante (eliminar una columna, agrupar una categoría, construir una variable, elegir un umbral) debe quedar documentada con su justificación dentro del propio notebook, en una celda de texto junto al código correspondiente.

Entregables

Al finalizar el plazo, el equipo debe entregar los siguientes archivos:

- Notebook de trabajo ejecutado de principio a fin, sin errores, desarrollado a partir del archivo `Capstone_DataCoSupplyChain_guia_estudiante.ipynb`, con todas las celdas de código completadas y las celdas de justificación redactadas.
- Documento de reporte (memoria de trabajo) con las respuestas a las preguntas de la sección "Reporte de resultados" de este documento.

Datos

El caso utiliza el dataset público DataCo Smart Supply Chain, que contiene el registro histórico de aproximadamente 180,519 pedidos de una operación real de comercio electrónico, con 53 columnas originales que describen al cliente, al producto, al pedido, al envío y a la tienda. El archivo se entrega en formato CSV, codificación de texto Latin-1 (ISO-8859-1) y separado por comas.

Archivos entregados:

- Dataset.csv: dataset completo (180,519 filas, 53 columnas). Es el archivo que se debe usar para el desarrollo del caso.
- Dataset_sample.csv: extracto de 5 filas, útil únicamente para inspeccionar rápidamente la estructura de las columnas antes de cargar el archivo completo.
- Dataset_description.csv: descripción oficial (en inglés) de cada columna, tal como la publica la fuente original del dataset. El Anexo de este documento incluye una versión traducida y organizada de este diccionario de datos.

El dataset se entrega tal como se distribuye públicamente: incluye columnas identificadoras, columnas vacías o casi vacías, columnas duplicadas bajo otro nombre, columnas de texto libre y al menos una columna que revela directamente la variable objetivo. Identificar y justificar el tratamiento de estos casos es parte del trabajo del caso, no un paso ya resuelto.

Procedimiento

El procedimiento se organiza en 5 etapas. El detalle paso a paso, con el contexto, la tarea específica y el resultado esperado de cada uno, se encuentra en el notebook complementario Capstone_DataCoSupplyChain_guia_estudiante.ipynb, que debe usarse junto con este documento.

Etapas 1. Exploración y preparación de los datos

1. Cargar el dataset completo y realizar una exploración inicial (dimensiones, tipos de dato, valores nulos, balance de la variable objetivo).
2. Detectar y eliminar columnas duplicadas (mismo contenido bajo distinto nombre).
3. Identificar y excluir las columnas que representan fuga de datos respecto a Late_delivery_risk.
4. Eliminar columnas identificadoras, de datos personales, vacías o casi vacías, enlaces y columnas de geografía redundante, documentando el criterio detrás de cada eliminación.

Etapas 2. Ingeniería de variables

5. Construir la variable Retraso_dias a partir de las columnas de días de envío real y programado, y verificar por qué no puede usarse como variable de entrada del modelo.
6. Construir (de forma opcional, como reto adicional) la variable Distancia_km entre la tienda y el centroide del mercado de destino.

Etapa 3. Codificación y particionamiento

7. Agrupar las categorías poco frecuentes de las columnas categóricas de mayor cardinalidad.
8. Aplicar codificación one-hot a las columnas categóricas seleccionadas.
9. Dividir el dataset en conjuntos de entrenamiento, validación y prueba.
10. Escalar las variables numéricas ajustando el escalador únicamente con el conjunto de entrenamiento.

Etapa 4. Construcción y entrenamiento del modelo

11. Definir la arquitectura de la red neuronal para un problema de clasificación binaria.
12. Configurar función de pérdida, optimizador y métricas adecuadas para el problema.
13. Entrenar el modelo utilizando EarlyStopping sobre la pérdida de validación.

Etapa 5. Evaluación e interpretación

14. Evaluar el modelo sobre el conjunto de prueba: exactitud, matriz de confusión y reporte de clasificación.
15. Interpretar los resultados desde la perspectiva del negocio y responder la sección "Reporte de resultados" de este documento.

Reporte de resultados

Con base en el trabajo realizado en el notebook, elabora una memoria de trabajo (formato libre) que responda, de forma argumentada, las siguientes preguntas:

1. Decisiones y criterio de preparación de datos: ¿qué columnas eliminaste y por qué? ¿qué columna(s) representaban fuga de datos y cómo lo comprobaste? ¿hubo alguna decisión donde dos personas razonables podrían haber elegido distinto (por ejemplo, qué hacer con Order Status)? Explica tu criterio.
2. ¿Qué variables de ingeniería construiste y qué evidencia tienes de que fueron calculadas correctamente?

3. Rendimiento general: ¿cuál fue la exactitud del modelo en el conjunto de prueba? ¿qué muestra la matriz de confusión sobre los dos tipos de error (falsos positivos y falsos negativos) y cuál de los dos es más costoso para el negocio en este caso?
4. Interpretación y aplicabilidad de negocio: si tuvieras que explicarle este modelo a la gerencia de operaciones de GlobalCart, ¿qué tan confiable dirías que es? ¿lo recomendarías para apoyar una decisión operativa real, o solo como un primer diagnóstico? Justifica tu respuesta con las métricas obtenidas.
5. Rol de la inteligencia artificial generativa: ¿en qué pasos te ayudó más la IA? ¿hubo algún caso en el que su sugerencia inicial fuera incorrecta, incompleta o tuviste que corregirla? Descríbelo.
6. Limitaciones y siguientes pasos: ¿qué limitaciones tiene el análisis actual? ¿qué harías distinto o qué información adicional pedirías si continuaras este proyecto?

Métrica de evaluación

La evaluación del caso pondera de forma más importante la calidad del criterio y la documentación de las decisiones que la ejecución técnica en sí misma, en línea con el objetivo del caso.

Componente	Descripción	Ponderación	Nota obtenida
Preparación y decisiones documentadas	Identificación y justificación de columnas eliminadas, fuga de datos y variables de ingeniería construidas.	35%	
Construcción y entrenamiento del modelo	Arquitectura de la red, configuración de codificación/escalado/partición y uso correcto de EarlyStopping.	25%	
Evaluación e interpretación de negocio	Cálculo correcto de las métricas de evaluación y calidad del análisis de negocio a partir de ellas.	20%	
Memoria de trabajo	Claridad, argumentación y completitud de las respuestas de la sección "Reporte de resultados".	20%	
Total		100%	

Anexo: diccionario de datos completo

A continuación se listan las 53 columnas originales del dataset Dataset.csv, con su tipo de dato en pandas (al cargar el archivo con codificación ISO-8859-1) y una descripción funcional de cada una. Esta tabla es la referencia oficial para las decisiones de la Etapa 1.

Columna	Tipo (pandas)	Descripción
Type	object	Tipo de transacción de pago realizada en el pedido.
Days for shipping (real)	int64	Días reales que tardó el envío del pedido.
Days for shipment (scheduled)	int64	Días de envío programados para el pedido.
Benefit per order	float64	Ganancia obtenida por pedido.
Sales per customer	float64	Total de ventas por cliente en el pedido.
Delivery Status	object	Estado de la entrega: Advance shipping, Late delivery, Shipping canceled, Shipping on time.
Late_delivery_risk	int64	Variable objetivo del caso: indica si el envío llegó tarde (1) o a tiempo (0).
Category Id	int64	Código de la categoría del producto.
Category Name	object	Nombre/descripción de la categoría del producto.
Customer City	object	Ciudad donde el cliente realizó la compra.
Customer Country	object	País donde el cliente realizó la compra.
Customer Email	object	Correo electrónico del cliente.
Customer Fname	object	Nombre del cliente.
Customer Id	int64	Identificador del cliente.
Customer Lname	object	Apellido del cliente.
Customer Password	object	Clave del cliente (enmascarada).
Customer Segment	object	Tipo de cliente: Consumer, Corporate, Home Office.
Customer State	object	Estado/departamento asociado a la tienda donde se registró la compra.
Customer Street	object	Calle asociada a la tienda donde se registró la compra.
Customer Zipcode	int64	Código postal del cliente.
Department Id	int64	Código del departamento de la tienda.
Department Name	object	Nombre del departamento de la tienda.
Latitude	float64	Latitud de la ubicación de la tienda.
Longitude	float64	Longitud de la ubicación de la tienda.
Market	object	Mercado al que se entrega el pedido: Africa, Europe, LATAM, Pacific Asia, USCA.
Order City	object	Ciudad de destino del pedido.
Order Country	object	País de destino del pedido.
Order Customer Id	int64	Código de cliente asociado al pedido.
order date (DateOrders)	object	Fecha en que se realizó el pedido.
Order Id	int64	Código del pedido.
Order Item Cardprod Id	int64	Código del producto generado por el lector RFID.
Order Item Discount	float64	Valor del descuento aplicado al artículo del pedido.

Order Item Discount Rate	float64	Porcentaje de descuento aplicado al artículo del pedido.
Order Item Id	int64	Código del artículo del pedido.
Order Item Product Price	float64	Precio del producto sin descuento.
Order Item Profit Ratio	float64	Razón de ganancia del artículo del pedido.
Order Item Quantity	int64	Cantidad de productos por pedido.
Sales	float64	Valor en ventas del artículo (precio por cantidad).
Order Item Total	float64	Monto total por pedido.
Order Profit Per Order	float64	Ganancia por pedido.
Order Region	object	Región del mundo donde se entrega el pedido (por ejemplo, Central America, South America, Western Europe, entre otras).
Order State	object	Estado/departamento de la región donde se entrega el pedido.
Order Status	object	Estado del pedido: COMPLETE, PENDING, CLOSED, PENDING_PAYMENT, CANCELED, PROCESSING, SUSPECTED_FRAUD, ON_HOLD, PAYMENT_REVIEW.
Order Zipcode	float64	Código postal de destino del pedido (columna con alto porcentaje de valores vacíos).
Product Card Id	int64	Código del producto.
Product Category Id	int64	Código de la categoría del producto.
Product Description	float64	Descripción del producto (columna vacía en el dataset).
Product Image	object	Enlace a la imagen/página del producto.
Product Name	object	Nombre del producto.
Product Price	float64	Precio del producto.
Product Status	int64	Estado del inventario del producto: 1 no disponible, 0 disponible.
shipping date (DateOrders)	object	Fecha y hora exacta del envío.
Shipping Mode	object	Modo de envío: Standard Class, First Class, Second Class, Same Day.