



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Minitaller: Construyendo mi primera red neuronal.

Presenta: Erick Varela Guzmán.

Universidad Centroamericana José Simeón Cañas.

Objetivo de esta sesión

- Aplicar el proceso completo de clasificación con redes neuronales, desde la limpieza de datos hasta la evaluación del modelo, sobre un caso real de ventas: predecir si un prospecto se convertirá en cliente, usando datos de comportamiento y origen del lead.

4.1.

Actividad práctica



¿Este prospecto se convertirá en cliente?

- **Dataset:** Leads_taller.xlsx (hoja Leads + hoja Diccionario de datos).
- **Duración total:** 2:30 horas.
- **Formato:** parejas o tríos, con IA generativa como asistente de código. Los equipos deciden, la IA construye.

Indicaciones

1. Trabajar en parejas o tríos.
2. La dinámica funciona por etapas cronometradas. En cada etapa recibirán preguntas generales para investigar y decidir con criterio propio.
3. Pueden usar IA generativa como asistente para escribir o corregir código. La IA no decide por ustedes: cada decisión debe quedar justificada en una frase, por escrito o verbal.
4. Al finalizar el tiempo de cada etapa se revelará la tabla de tareas específicas, con pistas más concretas para los equipos que necesiten orientación adicional.

Etapa 1. Exploración.

El dataset tiene 9,240 filas y 10 columnas de entrada + 1 columna objetivo.

- ¿Cuál es la columna que queremos predecir? ¿Qué significa que valga 1? ¿Y 0?
- ¿Hay alguna columna que claramente no debería usarse como variable de entrada?
- Revisar la distribución de la variable objetivo: ¿qué tan parejas están las dos clases?
- De las 10 columnas restantes, ¿cuáles son numéricas y cuáles son categóricas?

Etapa 1. Exploración.

Columna / Aspecto	Decisión a tomar	Posible enfoque
Prospect ID	Es un identificador único, no un patrón de comportamiento	Excluir de las variables de entrada (X)
Converted	5,679 filas en 0 (61.5%) y 3,561 en 1 (38.5%)	Desbalance moderado: anotarlo, no requiere corrección agresiva
Tipos de dato	4 columnas numéricas, 5 categóricas, 1 identificador	Clasificarlas antes de decidir cómo limpiar cada una

Etapa 2. Datos numéricos y texto inconsistente

Esta etapa tiene 4 problemas escondidos.

- Revisar TotalVisits y Page Views Per Visit: ¿son las mismas filas las que están vacías, o son filas distintas? Si hay valores nulos, ¿Qué pasa si simplemente se eliminan esas filas? ¿Es posible aplicar otra técnica para quitar los nulos que no sea eliminar las filas?
- Revisar los valores únicos de Last Activity: ¿todas las filas tienen un valor?
- Revisar los valores únicos de Lead Source con detalle. ¿Se ve el mismo origen escrito de dos formas distintas?

Etapa 2. Tareas específicas

Columna	Problema	Posible enfoque
TotalVisits	137 filas sin dato	Imputar con la mediana, o eliminar (es menos del 2% del total)
Page Views Per Visit	137 filas sin dato (las mismas filas que TotalVisits)	Mismo criterio que TotalVisits
Last Activity	103 filas sin dato	Tratar como su propia categoría: "Sin actividad registrada"
Lead Source	36 filas sin dato, más una inconsistencia: "Google" (2,868 casos) y "google" (5 casos) son el mismo origen escrito distinto	Unificar mayúsculas antes de decidir qué hacer con los nulos

Codificación de variables categóricas

- Una red neuronal solo entiende números. Cuando una columna tiene categorías de texto (como Lead Source o Last Activity), hay que convertirla antes de entrenar.
- La técnica más común es **one-hot encoding**: cada categoría se vuelve su propia columna de 0 y 1.
- El problema: si una categoría casi no se repite en los datos, esa columna nueva casi no le enseña nada a la red, y solo agrega ruido.

Por eso conviene revisar cuántas veces aparece cada categoría antes de codificar.

Etapa 3. Categorías con cola larga

Esta etapa tiene 3 retos.

- Revisar cuántas categorías distintas tiene Lead Source. ¿Cuántas de ellas aparecen menos de 10 veces en las 9,240 filas?
- Hacer lo mismo con Last Activity. ¿Vale la pena que cada una tenga su propia columna en el modelo?
- Revisar Specialization: ¿todas las filas que no están vacías tienen un valor real? Mirar con cuidado el valor más repetido.

Etapa 3. Tareas específicas

Columna	Problema	Posible enfoque
Lead Source	13 categorías con menos de 10 casos cada una (28 filas en total): bing, google, Click2call, Social Media, Live Chat, Press_Release, blog, Pay per Click Ads, WeLearn, welearnblog_Home, youtubechannel, testone, NC_EDM	Agruparlas todas en una sola categoría, por ejemplo "Otro"
Last Activity	6 categorías con menos de 10 casos (21 filas en total): Approached upfront, View in browser link Clicked, Email Received, Email Marked Spam, Visited Booth in Tradeshow, Resubscribed to emails	Agruparlas en "Otro"
Specialization	1,942 filas tienen el valor "Select" (la persona no eligió nada en el formulario) y 1,438 están vacías: 3,380 filas sin dato real (36.6% del total)	Tratar "Select" como nulo; decidir entre crear la categoría "No especificado" o eliminar la columna

Etapa 4. Preparar el experimento

- Antes de entrenar cualquier modelo hay que separar los datos en tres grupos independientes, no dos:
 - **Entrenamiento:** con el que la red ajusta sus pesos.
 - **Validación:** con el que se decide cuándo detener el entrenamiento.
 - **Prueba:** que el modelo no ve nunca hasta la evaluación final.
- También hay que **escalar** las variables numéricas.
- ¿En cuántos conjuntos se debe dividir el dataset, y qué papel cumple cada uno?
- Después de codificar las categóricas, ¿cuántas columnas tiene finalmente la tabla de entrada?

Etapa 4. Tareas específicas

Aspecto	Decisión a tomar	Posible enfoque
División de datos	¿Dos conjuntos o tres?	Entrenamiento, validación y prueba, separados desde el inicio
Escalado	Las variables numéricas tienen escalas muy distintas entre sí	StandardScaler, ajustado solo con el conjunto de entrenamiento
Tamaño final de X	El one-hot de Lead Origin, Lead Source (agrupado), Last Activity (agrupado) y Specialization genera varias columnas nuevas	Confirmar cuántas columnas tiene X antes de construir la red

Etapa 5. Construir, justificar y evaluar

La etapa final: construir, comparar y decidir.

- ¿Cuántas neuronas de salida necesita este problema? ¿Sigmoides o softmax?
- ¿Qué debe vigilar EarlyStopping: el conjunto de entrenamiento, el de validación o el de prueba?
- Al evaluar, ¿alcanza con mirar el accuracy? ¿Qué otra cosa habría que revisar?

Etapa 5. Tareas específicas

Aspecto	Decisión a tomar	Posible enfoque
Capa de salida	Dos clases posibles (convierte / no convierte)	Dense(1, activation='sigmoid')
Entrenamiento	¿Qué conjunto vigila el momento de detenerse?	EarlyStopping sobre validación, nunca sobre prueba
Evaluación	El accuracy solo no cuenta toda la historia	Matriz de confusión + recall de la clase "Sí convierte"
Justificación final	¿El resultado obtenido justifica el uso de una red neuronal?	



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Fin de la presentación