



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Minitaller: Predicción del tiempo de interacción.

Presenta: Erick Varela Guzmán.

Universidad Centroamericana José Simeón Cañas.

Objetivo de esta sesión

- Aplicar el proceso completo de regresión con redes neuronales sobre el mismo caso de ventas de la sesión anterior, esta vez prediciendo **una variable continua en vez de una categoría**: ¿cuánto tiempo pasará un prospecto en el sitio web?
- **El dataset ya está limpio.** El foco de hoy no es la limpieza, sino lo que cambia al pasar de clasificación a regresión.

6.1.

Actividad práctica



¿Cuánto tiempo pasará este prospecto en el sitio?

- **Dataset:** Leads_limpio.xlsx. Ya limpio: no se repite el proceso de limpieza.
- **Duración total:** 2:30 horas.
- **Formato:** parejas o tríos, con IA generativa como asistente de código. Los equipos deciden, la IA construye.

Indicaciones

1. Trabajar en parejas o tríos.
2. La dinámica funciona por etapas cronometradas. En cada etapa recibirán preguntas generales para investigar y decidir con criterio propio.
3. Pueden usar IA generativa como asistente para escribir o corregir código. La IA no decide por el analista: cada decisión debe quedar justificada en una frase por escrito.
4. Al finalizar el tiempo de cada etapa se revelará la tabla de tareas específicas, con pistas más concretas para los equipos que necesiten orientación adicional.
5. El archivo de trabajo es Leads_limpio.xlsx. Ya no tiene valores vacíos ni categorías inconsistentes: ese trabajo se hizo en la sesión anterior.

Etapa 1. Explorar el nuevo objetivo.

El dataset tiene 9,240 filas. La pregunta de negocio cambió.

- Total Time Spent on Website es ahora la variable objetivo: **¿qué tipo de variable es, comparada con Converted?**
- Revisar su distribución: ¿entre qué valores se mueve? ¿Cuál es el promedio?
- 2,193 filas (23.7% del total) tienen exactamente 0 segundos. ¿Es un dato faltante disfrazado, o es un comportamiento real?
- Comparar el promedio de Total Time Spent on Website entre los leads que convirtieron y los que no. ¿Qué se observa?

Etapa 1. Tareas específicas

Columna / Aspecto	Decisión a tomar	Posible enfoque
Total Time Spent on Website	Nueva variable objetivo: numérica continua, de 0 a 2,272 segundos, media 487.7	Confirmar que este es el nuevo target, ya no Converted
Converted	Los leads que convirtieron pasan en promedio 738.5 segundos en el sitio; los que no, 330.4	Excluir de las variables de entrada
Ceros en el objetivo	2,193 filas con 0 segundos	Son leads reales que nunca interactuaron con el sitio, no un dato faltante: se conservan tal cual

Etapa 2. Preparar el experimento para regresión

Lo que ya conocen de la sesión pasada, más una novedad.

- ¿Deberíamos mantener la columnas "Converted" para este caso?
- ¿En cuántos conjuntos se divide el dataset, y por qué? (misma respuesta que en clasificación)
- Las variables de entrada (X) se escalan igual que antes. ¿Qué pasa con la variable objetivo (y) esta vez? ¿Necesita el mismo tratamiento que en clasificación? Revisar el ejemplo de Uber/Lyft visto en la clase síncrona: ¿cómo se escaló ahí la variable de precio?

Sesión 6.

Break



Etapa 2. Tareas específicas

Aspecto	Decisión a tomar	Posible enfoque
División de datos	Igual que en clasificación	Entrenamiento y prueba
Escalado de X	Variables numéricas y categóricas codificadas, con escalas distintas entre sí	StandardScaler, ajustado solo con entrenamiento
Escalado de y	El objetivo ahora es continuo, en segundos (0 a 2,272)	Se debe escalar también y: ¿StandardScaler o MinMaxScaler?

Etapa 3. Justificar antes de construir

La misma pregunta incómoda de la sesión pasada, aplicada a regresión: ¿hace falta una red neuronal?

- ¿Qué cambia en la capa de salida cuando el objetivo es un número, no una clase?
- ¿Sigue aplicando `binary_crossentropy` como función de pérdida? Si no, ¿cuál métrica es la más adecuada?

Etapa 3. Tareas específicas

Aspecto	Decisión a tomar	Posible enfoque
Capa de salida	El objetivo es un número continuo, no una probabilidad entre clases	Dense(1, activation='linear')
Función de pérdida	binary_crossentropy ya no aplica: no hay clases que comparar	mse, con mae como métrica de seguimiento

Etapa 4. Construir, entrenar y evaluar

La etapa final: construir, comparar y decidir.

- ¿Qué conjunto debe vigilar EarlyStopping?
- Si el modelo se equivoca en promedio por 150 segundos, ¿es mucho o poco?
¿Respecto a qué se compara ese número?
- ¿Alcanza con mirar el MAE, o conviene revisar también R^2 ?

Etapa 4. Tareas específicas

Aspecto	Decisión a tomar	Posible enfoque
Entrenamiento	Igual que en clasificación	EarlyStopping sobre val_loss, con el conjunto de validación
Evaluación	El error ahora se mide en segundos, no en aciertos y errores de clase	MAE, RMSE y R^2 , invirtiendo el escalado de y antes de interpretar
Interpretación de negocio	Un MAE en segundos no dice nada por sí solo	Compararlo contra la media (487.7 s) y contra el modelo base de la Etapa 3

Checkpoint final

- ✓ Total Time Spent on Website confirmado como variable objetivo, Converted excluido de las entradas
- ✓ Ceros del objetivo conservados como comportamiento real, no tratados como dato faltante
- ✓ Datos divididos en entrenamiento, validación y prueba
- ✓ X escalado con StandardScaler; y escalado con MinMaxScaler, ambos ajustados solo con entrenamiento
- ✓ Modelo base (regresión lineal) entrenado como punto de comparación
- ✓ Red neuronal con capa de salida linear y pérdida mse, entrenada con EarlyStopping sobre validación
- ✓ Evaluación hecha con MAE, RMSE y R^2 , interpretados en segundos y en el contexto del negocio
- ✓ Justificación redactada: ¿la red aportó valor frente al modelo simple? ¿Por qué sí o por qué no?
- ✓ Diferencia entre clasificación, regresión y clustering, explicada con sus propias palabras

Cierre del curso

Tres sesiones, tres preguntas distintas hechas al mismo tipo de datos:

- **Clasificación (sesión 4):** ¿este prospecto se convertirá en cliente?
- **Regresión (sesión 6):** ¿cuánto tiempo pasará en el sitio?
- **Clustering (mención de hoy):** ¿qué grupos naturales existen entre los prospectos, sin decirle al modelo cuáles buscar?

Pregunta de cierre para cada equipo: en su propio trabajo, ¿cómo reconocerían cuál de estos tres tipos de problema tienen enfrente, antes de escribir la primera línea de código?



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Tópicos para la ciencia de datos y la toma de decisiones.

Fin de la presentación