



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Visualización y análisis en Power BI.

Presenta: Erick Varela Guzmán.

Contacto: evarela@uca.edu.sv

Universidad Centroamericana José Simeón Cañas.

Objetivos de esta sesión

- Identificar los factores que generan datos "sucios" analizando las principales causas de inconsistencias en los datos.
- Explorar las herramientas de limpieza de datos en Power BI.
- Discutir sobre las principales técnicas para gestionar valores faltantes evaluando diferentes estrategias como la eliminación de registros incompletos y la imputación de valores.
- Optimizar la calidad de los datos en Power BI mediante la implementación de buenas prácticas en el tratamiento de datos sucios, garantizando una estructura coherente y lista para la visualización y generación de informes efectivos.


3.1

Limpieza de datos




La importancia del análisis de datos

- En la empresa se generan muchos datos: gastos, ingresos, beneficios, analizar el tráfico de productos, satisfacción de los clientes... ¡Muchos datos!
- Para obtener información relevante de todas estas métricas, un analista debe consolidarlas en modelos y realizar análisis, comparaciones y conclusiones, sin embargo, este proceso puede conllevar diferentes problemas.
- Los datos multicanal son ahora la norma, por lo que es de esperar que haya inconsistencias en diferentes conjuntos de datos.



Algunos desafíos

- Existe una diversidad de fuentes privadas y públicas para obtener datos. Esta diversidad de fuentes, también representa una diversidad de formatos de presentación de los datos.
- Los datos no siempre son de buena calidad.
- Sin datos de calidad no se pueden generar análisis de calidad.




Las seis dimensiones de la calidad de datos

Antes de limpiar hay que saber qué se está midiendo. Estas dimensiones dan el vocabulario para diagnosticar un dataset:


- **Exactitud:** el dato refleja la realidad del negocio (un precio de \$0 no es exacto).
- **Compleitud:** no faltan valores donde el proceso los exige (ventas sin fecha, totales vacíos).
- **Consistencia:** el mismo hecho se representa igual en todas partes ("Bodega Sur" y "BODEGA SUR").
- **Validez:** el valor respeta el tipo, el rango y el formato esperado (fechas del 2024, cantidades > 0).
- **Unicidad:** cada registro aparece una sola vez; sin duplicados por ID.
- **Oportunidad:** el dato está disponible cuando se necesita para decidir.

Algunas estadísticas interesantes



Fuente: H. Sarih, A. P. Tchangani, K. Medjaher and E. Pere, "Data preparation and preprocessing for broadcast systems monitoring in PHM framework," 2019 6th International Conference on Control, Decision and Information Technologies (CoDIT), Paris, France, 2019, pp. 1444-1449, doi: **10.1109/CoDIT.2019.8820370**.

¿Qué factores generan datos “sucios”?



¿Qué factores generan datos "sucios"?

Los datos sucios casi nunca son culpa de una persona: son el resultado natural de cómo se generan.


- **Captura manual:** campos de texto libre, ausencia de validaciones, prisa en el punto de venta.
- **Múltiples fuentes:** cada sistema define sus propios códigos, formatos de fecha y catálogos.
- **Exportaciones intermedias:** un CSV pierde tipos, ceros a la izquierda y separadores decimales.
- **Cambios de esquema:** el ERP añade columnas, renombra campos o cambia el formato del reporte.
- **Migraciones de sistemas:** arrastran datos históricos con reglas que ya no existen.
- **Diseño del reporte:** reportes pensados para imprimirse, con subtotales y encabezados de sección incrustados.
- **Falta de gobierno de datos:** cada sucursal o analista adopta su propia convención informal.

Data cleansing

La limpieza de datos, también conocida como depuración de datos, es el proceso crucial de identificar y corregir o eliminar errores, inconsistencias e imprecisiones en los conjuntos de datos. Su objetivo principal es garantizar que los datos sean precisos, completos y confiables para el análisis y la toma de decisiones.



Técnicas comunes de limpieza de datos



Manejo de Valores Faltantes

Rellenar o eliminar
datos faltantes

Detección de Valores Atípicos

Identificación y
manejo de
anomalías

Transformación de Datos

Ajuste de datos para
el análisis

Eliminación de Duplicados

Eliminación de
entradas de datos
repetidas

Manejo de Inconsistencias

Asegurando la
uniformidad de los
datos

Catálogo de problemas típicos en un archivo real

- Estructurales: filas completamente vacías y filas de sección ("--- Datos Sucursal Norte ---").
- Duplicados: registros repetidos por doble exportación o por reintentos del sistema.
- Casing inconsistente: "efectivo", "Efectivo" y "EFECTIVO" cuentan como tres categorías distintas.
- Espacios invisibles: espacios al inicio o al final que hacen que " Ana Pérez" y "Ana Pérez" no coincidan.
- Formatos de fecha mezclados: "2024-11-11", "26/08/2024" y "21-Dic-2024" en la misma columna.
- Unidades y símbolos: "5 unidades", "\$76.02", "USD 127.76": números que llegan como texto.
- Valores centinela: "N/A", "-", "999" o vacío usados para decir "no sé".
- Problemas de encoding: tildes perdidas por codificación ("Electronica" vs "Electrónica").

Técnicas para gestionar los valores faltantes

En la ciencia de datos y el aprendizaje automático, lidiar con los valores faltantes es un paso fundamental para garantizar procesos de análisis precisos y confiables.



Técnicas para gestionar los valores faltantes

Existen estrategias para abordar la falta de datos y minimizar su impacto en el análisis. A continuación, se presentan dos enfoques principales:

- **Eliminación:** implica eliminar filas o columnas con valores faltantes. Es un método sencillo, pero puede ser problemático si falta una parte significativa de los datos. Descartar demasiados datos puede afectar la fiabilidad de las conclusiones.
- **Imputación:** reemplaza los valores faltantes con estimaciones. Existen varias técnicas de imputación, cada una con sus fortalezas y debilidades.

¿Cuándo eliminar y cuándo imputar?

La decisión no es técnica, es de negocio. Estos criterios ayudan a sostenerla:

- **Volumen:** si falta menos del 5% y los faltantes parecen aleatorios, eliminar la fila suele ser seguro.
- **Concentración:** una columna con más del 40-50% de vacíos rara vez aporta; considerar descartarla.
- **Patrón:** si los faltantes se concentran en una sucursal o en un mes, eliminarlos sesga el análisis.
- **Criticidad:** no es lo mismo un total que se puede recalcular que una fecha de vencimiento desconocida.
- **Significado del vacío:** a veces el vacío es información (un producto no perecedero no tiene vencimiento).

Advertencia: imputar convierte una incertidumbre en un número que se ve tan sólido como los demás. Siempre marcar qué valores fueron imputados.

Técnicas de imputación

- **Imputación de media/mediana/moda:** reemplaza las entradas faltantes con el promedio (media), el valor medio (mediana) o el valor más frecuente (moda) de la columna correspondiente.
- **K-vecinos más cercanos (imputación KNN):** este método encuentra los puntos de datos más cercanos en función de las características disponibles y utiliza sus valores para estimar el valor faltante
- **Imputación basada en modelos:** implica la creación de un modelo estadístico para predecir los valores faltantes en función de otras características de los datos. Esta puede ser una técnica poderosa, pero requiere más experiencia y puede ser costosa en términos computacionales.

Cómo elegir la técnica de imputación

Cada técnica supone algo distinto sobre por qué falta el dato:

- **Media / mediana:** rápida, conserva el tamaño de la muestra, pero reduce la varianza y aplanla la distribución. Usar la mediana si hay valores extremos.
- **Moda:** única opción razonable para variables categóricas (método de pago, categoría).
- **Último valor conocido:** útil en series de tiempo ordenadas; en Power Query es el paso "Rellenar hacia abajo".
- **KNN:** usa registros parecidos para estimar; respeta mejor la estructura, pero es costosa y sensible a la escala.
- **Basada en modelos:** la más precisa cuando hay señal, la más fácil de sobreajustar y de justificar mal.

En Power BI la mayoría de casos se resuelve con reemplazo de valores, rellenar hacia abajo o una columna calculada; KNN y modelos pertenecen al flujo de Python/R.

Power query

- Como sugiere su nombre, **Power Query** es una potente herramienta de análisis de datos integrada con Power BI. Power Query es una aplicación para transformar y preparar datos, con la que es posible obtener datos de fuentes a través de una interfaz gráfica y aplicar transformaciones.



Power Query: recorrido por la interfaz

Cinco zonas explican casi todo lo que se hace en el editor:

- **Panel de consultas (izquierda):** las tablas cargadas y las consultas auxiliares.
- **Vista previa (centro):** una muestra de los datos, no la tabla completa.
- **Pasos aplicados (derecha):** el historial ordenado de cada transformación aplicada.
- **Cinta:** Inicio, Transformar, Agregar columna y Vista concentran las operaciones.
- **Barra de fórmulas:** muestra el código M del paso seleccionado.

Idea clave: Power Query no modifica el archivo original. Construye una receta que se vuelve a ejecutar en cada actualización.

Pasos aplicados y lenguaje M


Cada clic en la cinta escribe una línea de código M. Entenderlo convierte la limpieza en un proceso auditable.

- **Es secuencial:** los pasos se ejecutan en orden; cambiar el orden cambia el resultado (recortar antes o después de reemplazar no es lo mismo).
- **Es reversible:** cualquier paso se puede editar, renombrar o eliminar sin rehacer todo.
- **Es autodocumentable:** renombrar "Personalizada1" a "Estandarizar Sucursal" documenta el proceso sin escribir un manual aparte.
- **Es repetible:** al actualizar, los mismos pasos se aplican al archivo nuevo.
- **Es extensible:** Editor avanzado permite ver y modificar toda la consulta en M.

Buena práctica: nombrar los pasos importantes desde el primer día. El "yo" de dentro de seis meses lo va a agradecer.

Integración

Power Query está disponible en muchos productos y servicios de Microsoft.



Perfilado: ver el problema antes de resolverlo

En la pestaña Vista, tres herramientas diagnostican una tabla en segundos:

- **Calidad de columna:** porcentaje de valores válidos, con error y vacíos por columna.
- **Distribución de columnas:** cuántos valores distintos y cuántos únicos hay; delata el casing inconsistente y los duplicados.
- **Perfil de columna:** estadísticas de la columna seleccionada: mínimo, máximo, promedio, conteos.

Ajuste importante: por defecto el perfilado analiza solo las primeras 1000 filas. Cambiar a "basado en todo el conjunto de datos" en la barra de estado inferior.

Regla de la sesión: perfilar primero, transformar después. Sin perfilado se limpia a ciegas.

Un flujo de limpieza recomendado

El orden importa. Este flujo evita rehacer trabajo y es el que seguiremos en el ejemplo práctico:

- **1.** perfilar y entender el archivo (calidad y distribución de columnas).
- **2.** quitar ruido estructural: filas en blanco y filas de sección.
- **3.** quitar duplicados por identificador.
- **4.** homogeneizar texto: recortar espacios y unificar mayúsculas.
- **5.** corregir catálogos con reemplazo de valores (tildes, abreviaturas).
- **6.** quitar símbolos y unidades de las columnas numéricas.
- **7.** cambiar tipos de datos (fechas, enteros, decimales) al final del texto.
- **8.** tratar faltantes y valores atípicos con una regla explícita.
- **9.** verificar con Calidad de columna y renombrar los pasos.

Cambiar tipo antes de homogeneizar es el error más común: genera errores en cascada.



Ejemplos prácticos sesión 3

Ejemplo práctico 3.1: Demostración de un proceso de limpieza de datos.

Buenas prácticas en la limpieza de datos

- La limpieza de datos es un paso crucial en el proceso de análisis de datos, y no es diferente cuando se utiliza Power BI.
- En esta sección, analizaremos algunas prácticas recomendadas para la limpieza de datos en Power BI.
- Estas prácticas ayudarán a garantizar que sus datos sean precisos, coherentes y estén listos para el análisis.



Buenas prácticas: documentar.

Documentar los pasos de limpieza de datos es esencial para mantener la transparencia, la repetibilidad y la colaboración:

- Crear un documento que describe el proceso de limpieza.
- Describir claramente cada paso, como "Eliminar duplicados" o "Cambiar el nombre de las columnas".
- Especificar la fuente de datos o la tabla a la que se aplica el paso.
- Documentar transformaciones o los cálculos realizados durante el proceso de limpieza.
- Registrar los filtros o condiciones aplicados a los datos.
- Anote las fórmulas o expresiones personalizadas utilizadas.

Buenas prácticas: Uso de plantillas reutilizables

El uso de plantillas reutilizables en la limpieza de datos tiene varias ventajas:

- Coherencia: las plantillas garantizan que se apliquen los mismos pasos de limpieza de datos de manera uniforme en varios conjuntos de datos.
- Ahorro de tiempo.
- Eficiencia: las plantillas agilizan el proceso de limpieza de datos.
- Estandarización: las plantillas ayudan a aplicar prácticas de limpieza de datos estándar dentro de su organización.
- Escalabilidad: las plantillas se pueden compartir con otros miembros del equipo, lo que promueve la colaboración y la escalabilidad dentro de sus procesos de limpieza de datos.

Buenas prácticas: Automatizar

Automatizar los procesos de limpieza de datos puede ahorrar tiempo y garantizar la coherencia. Estos son los pasos para automatizar la limpieza de datos:

- Utilizar Power Query o Python para generar un script de limpieza.
- Implementar transformaciones como eliminar duplicados, manejar datos faltantes y cambiar el nombre de las columnas.
- Configurar las opciones de actualización de datos para ejecutar automáticamente el script de limpieza.

Nota: la automatización es un tema avanzado y requiere conocimiento de otras herramientas como lenguaje M.

Buenas prácticas: Revisión y actualización

Revisar y actualizar periódicamente los pasos de limpieza de datos es esencial para mantener la precisión e integridad de los datos en Power BI. Estos son algunos pasos a seguir:

- Establecer un cronograma para revisar y actualizar los procesos de limpieza.
- Realizar un seguimiento de los cambios o actualizaciones en las fuentes de datos.
- Analizar los pasos de limpieza actuales para identificar problemas o ineficiencias.
- Mantenerse informado sobre las nuevas características y funcionalidades en Power BI que pueden mejorar los procesos de limpieza de datos.

Errores frecuentes al limpiar datos

Lo que más cuesta caro en un proyecto real:

- **Eliminar primero, preguntar después:** borrar filas sin preguntar si esos vacíos significan algo para el negocio.
- **Confiar en un solo paso:** "Recortar" no arregla el casing ni los espacios internos.
- **Ignorar la configuración regional:** usar es-US con fechas en formato es-ES produce errores silenciosos o fechas invertidas.
- **Cambiar tipo demasiado pronto:** convertir texto a número antes de quitar "\$" o " unidades".
- **No renombrar los pasos:** quince pasos llamados "Personalizada1...15" que nadie puede auditar.
- **Limpiar fuera de Power Query:** modificar el CSV a mano rompe la repetibilidad de la actualización.
- **Validar solo con la vista previa:** el perfilado por defecto solo mira 1000 filas y da falsa tranquilidad.

Checklist de verificación final

Antes de cargar la tabla al modelo, comprobar que:

- Calidad de columna reporta 0% de errores en todas las columnas.
- los vacíos restantes están solo donde tienen sentido y hay una decisión documentada.
- cada columna tiene el tipo de dato correcto (fecha es fecha, no texto).
- el número de valores distintos coincide con el catálogo esperado del negocio.
- el conteo de filas cuadra con lo que la fuente dice que debería haber.
- los pasos aplicados están nombrados y en orden lógico.
- la consulta se actualiza sin errores al recargar el origen.

Del dato limpio al modelo: qué sigue

La limpieza no es el destino; es la condición de entrada al modelo.

- **Modelado:** separar hechos y dimensiones a partir de la tabla limpia.
- **Tabla de fechas:** toda tabla de hechos necesita una tabla calendario propia, no la columna Fecha.
- **Relaciones y jerarquías:** cada columna limpia se convierte en un segmentador o en un eje confiable.
- **Medidas DAX:** sobre datos sucios, cualquier medida calcula bien un número equivocado.

Cierre de la sesión: el dashboard más bonito no compensa una columna mal limpiada. La confianza en un informe se construye en Power Query.



Sección de discusión y preguntas



Postgrado en Ciencia de Datos e Inteligencia de Negocios:

Visualización y análisis en Power BI.

**Fin de la
presentación**